

3 MEST: Memória Episódica de Slots Tipados

A ideia do método cabe em uma frase: *uma pergunta sobre uma conversa passada já chega estruturada, e a memória deve ser guardada com a mesma estrutura*. Quando alguém pergunta “o que o James adotou em abril de 2022?”, a pergunta nomeia uma pessoa (James), uma ação (adotar) e uma data (abril de 2022), e deixa exatamente um campo em branco — o objeto —, que é justamente o que ela quer saber. Perguntas de memória conversacional são, quase sempre, uma tupla (**quem, fez-o-quê, com-o-quê, quando**) com um dos campos vazio. Um índice comum de palavras não enxerga essa estrutura: ele só sabe responder “quais trechos mencionam a palavra X ”. O **MEST** (*Memória Episódica de Slots Tipados*) guarda cada trecho da conversa já anotado com *quem* falou, *que ação* ocorreu, *sobre o quê*, de *que tipo* de coisa se trata e *quando* — e responde a pergunta procurando quem completa o campo que ficou vazio.

Em resumo, o método faz três movimentos. **(1) Recorta** cada conversa em *episódios*: pequenos blocos de turnos consecutivos que tratam do mesmo assunto, sendo o menor deles o par “pergunta e resposta” do diálogo. **(2) Pendura** cada episódio em cinco tipos de rótulo, os *slots*: ator, predicado, conceito, tipo e tempo. **(3) Traduz** a pergunta para esses mesmos cinco rótulos e pontua os episódios pelos rótulos que eles têm em comum com a pergunta, somando ainda um canal de similaridade textual. Duas propriedades atravessam os três movimentos: a memória é construída *sem nenhuma chamada a modelo de linguagem*, e *nenhum limiar foi escolhido olhando as respostas certas* — todos são estimados do próprio corpus (Seção 3.3).

3.1 Como a memória é construída

Uma única passagem de análise sintática por turno entrega de uma só vez quatro dos cinco slots: sintagmas nominais (**conceito**), lemas de verbos de conteúdo (**predicado**), menções a pessoas (**ator**) e datas (**tempo**, resolvidas contra a data da sessão e indexadas por ano, mês e dia). O quinto vem de elevar cada conceito aos seus hiperônimos na WordNet: é o slot **tipo**, que faz “quais *comidas*” alcançar um turno que diz “*frango assado*”.

O resultado é um grafo bipartido: de um lado os episódios, do outro os slots, e uma aresta sempre que aquele rótulo foi *literalmente pronunciado* naquele episódio — nada é inventado nem reescrito. Sobre esse grafo colocamos uma *rotação* (estrutura de *fatgraph*): uma ordem cíclica fixa das arestas em torno de cada vértice, $G = (V, H, \alpha, \sigma)$. A rotação é projetada, e rende dois objetos úteis. Em torno de um **slot**, a ordem é cronológica: percorrer essa órbita é ler “tudo o que esta pessoa, este verbo ou este tópico tocou, em ordem”, sem precisar ranquear nada. Em torno de um **episódio**, a ordem é sempre **ator** $\prec$ **predicado** $\prec$ **conceito** $\prec$ **tipo** $\prec$ **tempo**, e portanto os pares vizinhos — os *cantos* — são exatamente (quem, fez-o-quê), (fez-o-quê, com-o-quê) e (com-o-quê, quando). É a mesma tupla do primeiro parágrafo: uma pergunta é um canto com um lado em branco.

3.2 Como uma pergunta é respondida

A pergunta passa pelo mesmo extrator, o que produz o conjunto $\Lambda(q)$ dos slots que ela nomeia e que existem na memória. Cada slot encontrado “acende” os episódios ligados a ele, mas não

com o mesmo peso: um rótulo que aparece em 200 episódios não distingue nenhum deles, ao passo que um rótulo presente em três praticamente resolve a busca sozinho. Por isso o peso de um slot cai com o seu grau, e acima de um corte h_κ ele deixa de apontar episódios e vira só um bônus fixo — a regra é “*um rótulo muito comum serve de filtro, nunca de ponte*”. Somando os canais estruturais com um canal de similaridade textual, o escore de um episódio ε é

$$\begin{aligned}\psi(v) &= w_{\kappa(v)}(1 + \ln \deg(v))^{-\gamma} \text{ se } \deg(v) < h_\kappa; \quad \psi(v) = w_H \text{ caso contrário,} \\ s(\varepsilon) &= w_D \delta(q, \varepsilon) + \sum_{v \in \Lambda^*(q, \varepsilon)} \psi(v) + \beta \mathbb{K}[\varepsilon \in \text{Orb}(v^*)],\end{aligned}\tag{1}$$

em que $\Lambda^*(q, \varepsilon)$ são os slots da pergunta (exceto os de ator) ligados a ε , e $\delta(q, \varepsilon)$ é o maior cosseno entre a pergunta e o episódio ou qualquer um de seus turnos.

O termo β trata das perguntas que pedem uma *lista* (“quais comidas ela gosta?”). Aqui a estrutura de rotação faz algo que um buscador denso não faz: como a órbita de um slot já é a lista cronológica de tudo o que ele tocou, basta tomar o slot mais raro entre os que a pergunta nomeou e promover a órbita inteira — sem segunda busca nem reordenação.

O ator recebe tratamento diferente dos demais, e a razão é simples: como quase toda pergunta nomeia um dos falantes, somar um bônus por ator empurraria metade do grafo para cima e não separaria nada. O ator, portanto, não é um canal, é um *filtro*: $\hat{s}(\varepsilon) = s(\varepsilon) [\pi + (1 - \pi) \min(\omega(a, \varepsilon)/\Omega, 1)]$, onde $\omega(a, \varepsilon)$ mede quanto do conteúdo daquele episódio saiu da boca de a . Um episódio é um par de turnos e contém, por construção, fala dos dois participantes; então “ a falou aqui” não diz nada, mas “ a disse a maior parte disto” diz.

Uma última assimetria é proposital: quem torna um trecho *encontrável* é o episódio, mas quem ocupa o orçamento de *tokens* é o turno. Entregar episódios inteiros gastaria o orçamento com poucos blocos grandes e perderia amplitude; entregar turnos soltos, por outro lado, quebraria justamente o par pergunta–resposta que motivou o episódio. A solução é pontuar turnos, deixando que cada um herde o que o seu episódio conquistou:

$$s(t) = \hat{s}(\varepsilon(t)) + w_D \cos(q, x_t) + \lambda w_D \max_{t' \in \varepsilon(t), t' \neq t} \cos(q, x_{t'}).\tag{2}$$

O último termo é a regra do par escrita como aritmética: um turno herda uma fração λ da melhor semelhança entre os seus vizinhos de episódio. Assim, a resposta “era uma peça contemporânea chamada *Finding Freedom*” sobe junto com o turno que menciona o assunto, mesmo não tendo palavra alguma em comum com a pergunta. Tomam-se então os turnos em ordem decrescente até esgotar o orçamento.

3.3 De onde vêm os limiares

Resta uma pergunta incômoda: de onde saem h_κ , π e os demais números? Ajustá-los contra o conjunto anotado é prática comum, e é também o que impede levar um método a outro corpus. Adotamos um critério simples — *o parâmetro precisa das respostas certas para ser fixado?* — e trocamos cada constante por um estimador medido, durante a construção, sobre o corpus *não* anotado. O corte de rótulo comum vira o quantil 0,99 dos graus daquele

tipo, $h_\kappa = \lceil Q_{0,99}\{\deg(v) : v \in \mathcal{S}_\kappa\} \rceil$: uma contagem absoluta quebraria com a escala, pois num corpus dez vezes maior todo slot a ultrapassaria e o mecanismo se desligaria sozinho. Pelo mesmo raciocínio, o limiar de paráfrase vira um quantil alto dos cossenos realmente observados — é propriedade do codificador, não da tarefa — e o filtro de ator vira $\pi = 1/|\Sigma|$ e $\Omega = \text{mediana}_\varepsilon \max_a \omega(a, \varepsilon)$, apertando-se sozinho quando há mais falantes. Já as palavras que só servem de moldura (“conversa”, “data”, “tipo”) passam a ser detectadas por um contraste de frequências, o análogo do IDF do lado da pergunta: uma palavra de tópico é frequente nas perguntas *porque* o é nas conversas, ao passo que uma de moldura é frequente nas perguntas e ausente do que as pessoas disseram. Os pesos w_κ , λ e γ seguem fixos de propósito: afirmam algo sobre o *modelo* — que um casamento de conceito informa mais do que um palpite de hiperônimo —, não sobre o corpus.